

UNIVERSIDAD DE SANTIAGO DE CHILE
FACULTAD DE INGENIERÍA
Departamento de Ingeniería Industrial



PROYECTO INTEGRADOR: CLASIFICACIÓN SUPERVISADA

Perfilamiento de usuario para un determinado Banco

Integrantes del equipo

Alex Astudillo
Martina Bedwell
Sebastián Quintolen
Valentina Quiroz
Izaak Ulloa

PROFESOR:

Luis Rojo-González, Ph.D.

ASIGNATURA:

Estadística Aplicada

SANTIAGO – CHILE

2026

Resumen ejecutivo

Este proyecto aborda la decisión de a qué clientes de un banco retail portugués contactar telefónicamente para ofrecer un depósito a plazo, dado un equipo de agentes con capacidad limitada. La clase positiva es la suscripción del producto ($y = \text{"yes"}$). Se compararon ocho familias de modelos (baseline, regresión logística, KNN, SVM lineal, SVM con kernel RBF, árbol de clasificación, Random Forest y Gradient Boosting) bajo validación cruzada estratificada de 5 folds, con balanceo de clases y estandarización aplicados exclusivamente dentro de cada fold.

Se seleccionó Gradient Boosting como sistema final, con umbral de decisión determinado por el índice de Youden ($m^* = 0.4874$) sobre las predicciones de validación cruzada, tras confirmar que este criterio supera consistentemente a un umbral basado en costos bajo distintos supuestos de razón CF_N/CF_P (2 a 10), debido a una calibración imperfecta de las probabilidades inducida por el down-sampling.

Evaluated una única vez sobre el conjunto de test, el sistema alcanza $AUC \approx 0.78$ y Sensibilidad de 62.1 %, frente a 0 % del baseline no informativo. La política resultante ejecuta 1.664 llamadas de 8.234 clientes en test, capturando la mayoría de las ventas potenciales con una fracción del esfuerzo de contacto total.

Condición de uso: el sistema fue entrenado y validado sobre datos de 2008–2010 de una única institución; su desempeño reportado corresponde a una cota optimista frente a un despliegue prospectivo, y depende fuertemente de indicadores macroeconómicos agregados, por lo que requiere monitoreo activo ante cambios de contexto económico (ver Sección 13).

Palabras clave: clasificación supervisada; telemarketing bancario; Gradient Boosting Machine; índice de Youden.

Índice

Resumen ejecutivo	I
Índice de tablas	V
Índice de figuras	VI
1. Problema y objetivos	1
1.1. Contexto y decisión	1
1.2. Unidad de observación, clases y horizonte	1
1.3. Costos de los errores y capacidad	1
1.4. Objetivos	1
2. Búsqueda y descripción del dataset	2
2.1. Proceso de búsqueda y alternativa descartada	2
2.2. Fuente, licencia y condiciones de uso	3
2.3. Población, período y variables	3
3. Calidad de datos, etiquetas y análisis exploratorio	3
3.1. Auditoría de calidad	3
3.2. Prevalencia y distribución de clases	4
3.3. Decisiones derivadas del EDA	5
4. Instante predictivo y construcción del target	5
4.1. Instante de corte y horizonte	5
4.2. Regla de construcción de las clases	5
4.3. Riesgos de fuga y errores de etiquetado	6
5. Partición y resampling	6
5.1. Diseño de la partición	6
5.2. Esquema de validación	7

5.3. Protección del conjunto de test	7
6. Preparación de datos y tratamiento del desbalance	7
6.1. Preprocesamiento	7
6.2. Estrategia de desbalance	7
6.3. Implementación sin leakage	7
7. Modelos evaluados y ajuste de hiperparámetros	7
7.1. Baseline y regresión logística	7
7.2. KNN	8
7.3. SVM lineal y con kernel	9
7.4. Árbol de clasificación	11
7.5. Random Forest y boosting	12
7.6. Diseño del tuning	14
8. Discriminación y métricas de validación	15
9. Calidad probabilística y calibración	16
9.1. Diagnóstico de calibración	16
9.2. Método de calibración, si corresponde	16
9.3. Efecto sobre las probabilidades y la decisión	16
10. Selección del umbral o política de priorización	17
10.1. Criterio operacional	17
10.2. Punto de operación seleccionado	17
10.3. Sensibilidad a costos y capacidad	17
11. Sistema seleccionado y test final	18
11.1. Configuración congelada	18
11.2. Evaluación única en test	19
12. Interpretación, errores y subgrupos	20

12.1. Patrones predictivos	20
12.2. Análisis de falsos positivos y falsos negativos	20
12.3. Auditoría por subgrupos	20
13. Limitaciones, equidad y monitoreo	20
13.1. Limitaciones y transportabilidad	20
13.2. Riesgos de equidad y uso	22
13.3. Sesgos demográficos y el problema de los datos enmascarados (<i>Unknown</i>)	22
13.4. Desempeño y disparidad en subgrupos temporales	22
14. Plan de Monitoreo y Gobernanza Post-Despliegue	22
14.1. Indicadores de Alerta Temprana	23
14.2. Protocolo de Intervención	23
15. Conclusiones	23
15.1. Sistema Seleccionado y Política Comercial	24
15.2. Condiciones de Uso y Límites de Aplicación	24
Referencias	25
A. Información de reproducibilidad	25
B. Resultados complementarios	25
C. Declaración de uso de inteligencia artificial	25
D. Contribuciones del equipo	26

Índice de tablas

1.	Resultados de validación cruzada (5-fold CV) para los modelos evaluados	15
2.	Evaluación del sistema final congelado en conjunto de test.	19

Índice de figuras

1.	Distribución de la variable respuesta	4
2.	Distribución por edad	4
3.	Frecuencia de contactos por mes	5
4.	ROC - Regresión logística	8
5.	ROC de validación cruzada según k (KNN) (TRAIN)	8
6.	ROC de validación cruzada según k (KNN) (TEST)	9
7.	ROC de validación cruzada según C (SVM lineal)	9
8.	ROC - SVM lineal	10
9.	ROC de validación cruzada (SVM RBF)	10
10.	ROC - SVM RBF	11
11.	Diagrama del árbol de decisión	11
12.	Importancia de variables en el árbol	12
13.	ROC - Árbol de clasificación	12
14.	ROC de validación cruzada según mtry (Random Forest)	13
15.	Importancia de variables en Random Forest	13
16.	ROC - Random Forest	14
17.	Comparación [1]	14
18.	Comparación [2]	15
19.	Curvas de calibración	17
20.	Sensibilidad del umbral a la razón de costos	18
21.	ROC de validación cruzada (Gradient Boosting)	18
22.	ROC - Gradient Boosting	19

1. Problema y objetivos

1.1. Contexto y decisión

El equipo de marketing directo de un banco retail debe decidir, con recursos de contacto limitados, a qué clientes llamar para ofrecerles un depósito a plazo. Esta es una decisión de clasificación porque requiere anticipar, antes del contacto, si un cliente aceptará o no el producto, y así **priorizar el uso del tiempo de los agentes** —un problema de asignación de recursos escasos bajo incertidumbre, propio de la Ingeniería Industrial.

1.2. Unidad de observación, clases y horizonte

- **Unidad de Observación:** Un contacto comercial telefónico a un cliente bancario individual.
- **Clase Negativa (no):** El cliente rechaza la propuesta de depósito a plazo.
- **Clase Positiva (yes):** El cliente acepta contratar el depósito a plazo.
- **Instante Predictivo (Corte):** Momento exacto previo a realizar la llamada comercial.
- **Horizonte de Evaluación:** Campaña trimestral de captación de fondos.
- **Población Objetivo:** Clientes de la base bancaria general elegibles para productos de inversión.

1.3. Costos de los errores y capacidad

- **Falso Positivo (FP):** Clasificar como aceptante a un cliente que rechazará la oferta. Costo operacional (CF_P): Pérdida directa del tiempo del ejecutivo y uso del canal telefónico, estimado en 1 unidad ($CF_P = 1$).
- **Falso Negativo (FN):** Clasificar como no aceptante a un cliente que habría contratado el depósito. Costo operacional (CF_N): Pérdida de oportunidad equivalente al margen financiero del depósito no captado, valorado en 5 unidades ($CF_N = 5$).
- **Restricción de Capacidad:** El call center dispone de capacidad operativa máxima para contactar hasta un 25 % de la cartera general por trimestre.

1.4. Objetivos

- **Objetivo General:** Construir y seleccionar, mediante un protocolo riguroso de validación, un sistema de clasificación que apoye la decisión de a qué clientes contactar, superando a un baseline no informativo en la detección de clientes con probabilidad real de aceptar el producto.

- **Objetivo Específico 1:** Entrenar 8 familias de clasificadores utilizando validación cruzada de 5 pliegues con preprocesamiento interno (*down-sampling*) para garantizar un ROC-AUC > 0.78 sin fuga de información (*data leakage*).
- **Objetivo Específico 2:** Seleccionar un umbral de decisión operacional comparando el índice de Youden contra un umbral basado en costos ($CF_P = 1, CF_N = 5$), con análisis de sensibilidad a este supuesto.
- **Objetivo Específico 3:** Auditar el desempeño del sistema seleccionado en al menos un subgrupo operacional relevante (mes de contacto), caracterizando sus falsos positivos y falsos negativos.

2. Búsqueda y descripción del dataset

2.1. Proceso de búsqueda y alternativa descartada

Se evaluaron datasets de dominios cercanos a Ingeniería Industrial (mantenimiento predictivo, fraude, entre otros). La decisión de usar Bank Marketing se basó en: (1) licencia clara y sin ambigüedad, (2) datos reales de una operación de negocio, y (3) la disponibilidad de más de 8 predictores al instante de decisión.

Alternativa descartada: Se descartó un “mirror” de Kaggle ([prakharrathi25/banking-dataset-marketing-targets](https://www.kaggle.com/prakharrathi25/banking-dataset-marketing-targets)) porque su licencia estaba etiquetada inconsistentemente (CC0), contradiciendo la licencia CC BY 4.0 original que exige atribución explícita, además de carecer de versionado estable.

Justificación de la elección del dataset (La elección más pertinente): Se seleccionó el dataset Bank Marketing porque permite abordar directamente la decisión de priorización de clientes en una campaña de marketing telefónico, utilizando una variable objetivo binaria que indica si el cliente suscribió o no el depósito a plazo. Además, se trata de datos reales provenientes de una campaña bancaria, por lo que el problema representa una situación de decisión concreta y no una simulación. Frente a las otras alternativas revisadas, Bank Marketing resulta especialmente pertinente porque cuenta directamente con más de ocho predictores disponibles al momento de la decisión, tales como edad, trabajo, educación, saldo, créditos, hipoteca, préstamo personal y resultados de campañas anteriores, sin requerir una etapa adicional de ingeniería de variables para cumplir con los requisitos del proyecto. Esto permite concentrar el análisis en la comparación de modelos, la validación y la construcción de una política de decisión. Además, el dataset permite formular claramente los costos asociados a la decisión: contactar a un cliente que no estaba interesado implica utilizar recursos de los agentes sin obtener el resultado esperado, mientras que no contactar a un cliente que habría aceptado implica perder una oportunidad potencial de venta. Esto permite conectar directamente el problema estadístico con una decisión operacional. Finalmente, la estructura temporal de los datos y la existencia de subgrupos relevantes permiten realizar análisis adicionales de estabilidad y desempeño, mientras que la presencia de la variable *duration* entrega un caso concreto de fuga de información que debe ser detectado y excluido por no estar disponible en el instante de predicción.

2.2. Fuente, licencia y condiciones de uso

- **Fuente y URL:** UCI Machine Learning Repository (ID 222). <https://archive.ics.uci.edu/dataset/222/bank+marketing>
- **Autores:** S. Moro, P. Cortez, y P. Rita (2014).
- **DOI:** 10.24432/C5K306
- **Licencia:** Creative Commons Attribution 4.0 International (CC BY 4.0).
- **Fecha de acceso:** 16 de julio de 2026.
- **Citación:** Moro, S., Cortez, P., & Rita, P. (2014). A Data-Driven Approach to Predict the Success of Bank Telemarketing. *Decision Support Systems*, 62, 22–31.
- Diccionario completo de variables en DATASET_README.md

2.3. Población, período y variables

- **Población y Período:** Muestra de clientes contactados por un banco retail portugués, entre mayo de 2008 y noviembre de 2010.
- **Volumen Muestral:** 41.188 observaciones iniciales (41.176 tras eliminar 12 duplicados exactos). Originalmente 41.188 observaciones 21 columnas.
- **Prevalencia Global:** 11.27 % de casos positivos (yes) vs 88.73 % de negativos (no).
- **Variables:** 21 atributos originales divididos en demográficos, financieros, de campaña previa e indicadores macroeconómicos.

La carpeta debe incluir DATASET_README.md, escrito en Markdown y legible en GitHub, con el diccionario completo de variables. Se evalúa la calidad documental, no el uso de una plataforma de control de versiones.

3. Calidad de datos, etiquetas y análisis exploratorio

3.1. Auditoría de calidad

Se removieron 12 duplicados exactos en el conjunto fuente (`datos[!duplicated(datos), ]`). Las variables continuas con delimitador decimal europeo (`emp.var.rate`, `cons.price.idx`, `cons.conf.idx`, `euribor3m`, `nr.employed`) fueron reconvertidas a tipo numérico. La categoría "unknown" en variables financieras (`default`, `housing`, `loan`) se mantuvo como un nivel explícito para preservar patrones conductuales.

3.2. Prevalencia y distribución de clases

La distribución de la clase respuesta refleja un desbalance severo: 36,536 registros negativos (no) y 4,640 registros positivos (yes), determinando una prevalencia del 11.27%. El análisis exploratorio reveló que clientes contactados en períodos con baja tasa Euribor o con antecedentes de suscripción previa (pout come = "success") presentan tasas de conversión superiores al 60%.




Figura 1: Distribución de la variable respuesta




Figura 2: Distribución por edad




Figura 3: Frecuencia de contactos por mes

3.3. Decisiones derivadas del EDA

Se detectó que la variable *duration* (duración de la llamada) constituye un caso crítico de *Data Leakage*, dado que solo se conoce al finalizar el contacto comercial. Se decidió eliminarla permanentemente del pipeline de predicción. Asimismo, el drift de prevalencia observado entre meses motiva la discusión de partición temporal vs. aleatoria en la Sección 5, y a *month* como candidato de auditoría de subgrupo en la Sección 12.

4. Instante predictivo y construcción del target

4.1. Instante de corte y horizonte

El instante de decisión es **antes de realizar la llamada**. En ese momento el banco dispone de las variables sociodemográficas del cliente, el historial de contactos previos (*campaign*, *pdays*, *previous*, *poutcome*) y los indicadores socioeconómicos vigentes (*emp.var.rate*, *cons.price.idx*, *cons.conf.idx*, *euribor3m*, *nr.employed*). El horizonte de predicción es el resultado de la llamada actual.

4.2. Regla de construcción de las clases

y se construye directamente del registro histórico de la campaña: si el cliente contrató o no el depósito luego de la llamada, sin necesidad de definir un horizonte de observación adicional.

4.3. Riesgos de fuga y errores de etiquetado

No existe documentación oficial de UCI que indique casos de llamadas interrumpidas o sin respuesta definitiva antes de asignar *y*; se asume que cada fila representa un contacto con un desenlace binario ya resuelto (acepta / no acepta) al momento de finalizar la llamada. Los casos con *duration* = 0 (posibles cortes inmediatos o buzones de voz) quedan naturalmente excluidos del riesgo de fuga al eliminar *duration* del modelamiento, pero podrían representar una categoría distinta de “no” que no se distingue explícitamente en los datos.

No hay evidencia de retraso entre el contacto y el registro del resultado: y parece corresponder al desenlace inmediato de cada llamada, sin una ventana de seguimiento posterior (por ejemplo, no se registra si un cliente que aceptó luego revocó la contratación).

Riesgo de dependencia entre observaciones: el dataset no incluye un identificador único de cliente. Dado que *pdays* y *previous* indican contactos anteriores, es probable que un mismo cliente aparezca en múltiples filas a lo largo de distintas campañas. Este proyecto asume independencia entre observaciones, lo cual es una simplificación: los modelos podrían estar viendo, sin saberlo, múltiples registros de un mismo cliente repartidos entre entrenamiento y validación/test, introduciendo una fuga leve de información específica del cliente (no solo del instante temporal). Se documenta como limitación no resuelta en este proyecto.

5. Partición y resampling

5.1. Diseño de la partición

Se aplicó una partición estratificada del 80% para entrenamiento ($N = 32,942$) y 20% para prueba ($N = 8,234$) mediante `createDataPartition` fijando la semilla `set.seed(123)`. Ambas particiones conservaron exactamente el 11.27% de prevalencia de la clase positiva. Se evaluó también una partición temporal (entrenar con los primeros meses de campaña, evaluar sobre los más recientes), motivada por el drift de prevalencia detectado en el EDA. Se comparó el AUC de un modelo de control (regresión logística) bajo ambos esquemas: **0.775 con partición aleatoria vs. 0.714 con partición temporal**. Se optó por mantener la partición aleatoria estratificada por tres razones: (1) el cronograma del proyecto no permitía reentrenar las ocho familias de modelos con validación *rolling-origin* sin comprometer la profundidad del análisis de calibración, umbral y subgrupos; (2) los folds *rolling-origin* resultantes son de tamaño muy desigual, introduciendo alta varianza en la selección de hiperparámetros; y (3) el bloque de test temporal presenta una prevalencia de 44.5%, sugiriendo un régimen de campaña particular y transitorio, no necesariamente más representativo de la variabilidad natural entre clientes que este proyecto busca modelar. Se reconoce esta decisión como una limitación real (ver Sección 13).

5.2. Esquema de validación

Dentro del conjunto de entrenamiento se configuró una Validación Cruzada Estratificada de 5 pliegues (5-fold CV) mediante la función `train`.

5.3. Protección del conjunto de test

test permanece congelado desde este punto: no se usa para elegir modelo, hiperparámetros, calibración ni umbral. Se abre una única vez en la Sección 11.

6. Preparación de datos y tratamiento del desbalance

6.1. Preprocesamiento

Las categóricas se transformaron mediante codificación One-Hot (`dummyVars`) produciendo 52 variables numéricas. La estandarización (*center/scale*) se ejecutó como un paso interno en cada pliegue.

6.2. Estrategia de desbalance

Se implementó submuestreo (*down-sampling*) sobre la clase mayoritaria en entrenamiento.

6.3. Implementación sin leakage

Los ocho modelos entrenados en la Sección 7 usan `preProcess = c("center","scale")` como argumento de `train()` (no el `x_train_std` calculado arriba), de forma que `caret` recalcula el centrado/escalado **dentro de cada fold** de validación cruzada, evitando la fuga de información hacia el fold de validación que tendría usar un `x_train_std` calculado una sola vez sobre todo `train`. Del mismo modo, el balanceo de clases (`sampling = "down"`) se aplica exclusivamente dentro de cada fold de entrenamiento, nunca antes de la partición ni sobre `train` completo.

7. Modelos evaluados y ajuste de hiperparámetros

7.1. Baseline y regresión logística

Asigna la clase mayoritaria ("no"). Se ajustó un modelo binomial `glm`.




Figura 4: ROC - Regresión logística

El baseline logra $\tilde{89}\%$ de Accuracy solo por predecir siempre “no”, con Sensibilidad 0. La regresión logística alcanza $AUC \approx 0.775$; variables más significativas: `contact`, `emp.var.rate`, `cons.price.idx`, `month`, `poutcome`, `campaign`, `previous`.

7.2. KNN

Sintonizado mediante la grilla $k \in \{3, 7, 11, \dots, 51\}$, seleccionando $k = 47$. Tras confirmar que el óptimo no quedaba en el borde). $AUC \approx 0.763$, consistente con la “maldición de la dimensionalidad” en 51 predictores tras dummies.




Figura 5: ROC de validación cruzada según k (KNN) (TRAIN)




Figura 6: ROC de validación cruzada según k (KNN) (TEST)

7.3. SVM lineal y con kernel

SVM Lineal sintonizado con $C \in \{0.01, 0.1, 1, 10\}$ (óptimo $C = 0.1$). SVM RBF sintonizado con $\sigma \in \{0.01, 0.05\}$ y $C \in \{0.5, 1.0\}$ (óptimo $\sigma = 0.01, C = 1.0$). En algunas ejecuciones, el ajuste interno de calibración de probabilidades de kernlab puede generar valores NA en algún fold cuando el submuestreo produce separación casi perfecta entre clases (se observó dependencia de la versión de R utilizada). Esto se maneja explícitamente en la Sección 8.




Figura 7: ROC de validación cruzada según C (SVM lineal)




Figura 8: ROC - SVM lineal




Figura 9: ROC de validación cruzada (SVM RBF)




Figura 10: ROC - SVM RBF

7.4. Árbol de clasificación

Podado mediante parámetro de complejidad $cp \in [0.001, 0.05]$, seleccionando $cp = 0.001$ (borde inferior probado; no se bajó más por riesgo de sobreajuste, decisión documentada). $AUC \approx 0.752$, el más bajo de los 7 modelos con predictores.




Figura 11: Diagrama del arbol de decisión




Figura 12: Importancia de variables en el árbol




Figura 13: ROC - Árbol de clasificación

7.5. Random Forest y boosting

Random Forest entrenado con 300 árboles ($mtry \in \{2, 4, 9\}$, óptimo $mtry = 4$). Gradient Boosting Machine (GBM) sintonizado con $n.trees = 200$, $interaction.depth = 3$, $shrinkage = 0.10$ y $n.minobsinnode = 10$. $AUC \approx 0.771$. Gradient Boosting (grilla acotada por tiempo, 8 combinaciones): $AUC \approx \mathbf{0.782}$, el mejor de los 8 modelos, junto con la mejor Sensibilidad (≈ 0.617)




Figura 14: ROC de validación cruzada según mtry (Random Forest)




Figura 15: Importancia de variables en Random Forest




Figura 16: ROC - Random Forest

7.6. Diseño del tuning

Las grillas de hiperparámetros se ampliaron cuando el óptimo caía en el borde de la grilla inicial (caso de KNN: de $\text{seq}(3, 25, 2)$ a $\text{seq}(3, 51, 4)$), y se documentaron explícitamente los casos donde no se amplió por restricciones de tiempo (SVM RBF, Árbol). Todos los modelos comparten el mismo `trainControl` (mismos 5 folds exactos), lo que permite comparaciones formales de variabilidad (Sección 8).




Figura 17: Comparación [1]




Figura 18: Comparación [2]

Boosting tiene el mayor ROC promedio, pero su intervalo de confianza al 95 % se traslapa con Random Forest, Logística e incluso KNN — con solo 5 folds no se puede afirmar con confianza estadística que Boosting sea significativamente mejor que esos otros tres modelos.

8. Discriminación y métricas de validación

Tabla 1: Resultados de validación cruzada (5-fold CV) para los modelos evaluados

Modelo	ROC-AUC	PR-AUC	Log-loss	Precision	Recall	Especificidad	F1	Costo	Volumen
Baseline	0.5000	N/A	N/A	NaN	0.0000	1.0000	0.0000	18565	0
Logística	0.7946	0.4412	0.5201	0.3423	0.8428	0.6441	0.4470	11200	6986
KNN	0.7835	0.4120	0.5610	0.3321	0.8337	0.6307	0.4320	11850	7100
SVM lineal	0.7794	0.4015	0.5420	0.3275	0.8606	0.6218	0.4285	11920	7310
SVM kernel	0.7850	0.4024	0.5259	0.3524	0.8242	0.6639	0.4410	11150	6780
Árbol	0.7758	0.3980	0.5310	0.3412	0.8512	0.6485	0.4402	11380	7020
Random Forest	0.7945	0.4323	0.4470	0.3672	0.8599	0.6401	0.4667	10774	6470
Boosting	0.8023	0.4527	0.5135	0.3486	0.8440	0.6576	0.4557	10916	7002

Gradient Boosting Machine (GBM) obtuvo la mayor capacidad de separación discriminativa con un ROC-AUC medio de 0.8023 y un PR-AUC de 0.4527.

9. Calidad probabilística y calibración

9.1. Diagnóstico de calibración

El submuestreo ajusta la muestra de entrenamiento a una proporción 50/50, desplazando la escala probabilística asignada. Por este motivo, las salidas deben entenderse como un **score de ordenamiento (ranking)**.

9.2. Método de calibración, si corresponde

No se aplicó recalibración de probabilidades (Platt scaling / isotónica) por dos razones. Primero, ajustar un calibrador sin sobreajustarlo exige dividir los datos en un subconjunto de ajuste y uno de evaluación separados; con solo 11.3 % de prevalencia y datos ya reducidos por el down-sampling dentro de cada fold, dividirlos nuevamente habría dejado muy pocos casos positivos para un ajuste confiable del calibrador, introduciendo un nuevo punto de inestabilidad al pipeline. Segundo, y más importante, el criterio de umbral finalmente utilizado (índice de Youden) depende únicamente del ranking relativo entre clientes, no del valor absoluto de la probabilidad — el análisis de sensibilidad de costos (razones CF_N/CF_P entre 2 y 10, Sección 10) confirma que este ranking es robusto pese a la falta de calibración. Dado que la decisión operacional final no dependía de tener probabilidades bien calibradas, se optó por no introducir la complejidad adicional de un calibrador, sin que esto comprometiera la validez de la política de umbral seleccionada.

9.3. Efecto sobre las probabilidades y la decisión

El orden relativo entre clientes sigue siendo válido (ROC/PR-AUC son buenos), pero las probabilidades crudas no son directamente interpretables como probabilidades reales. Random Forest tiene el mejor Log-Loss (≈ 0.447) de los tres candidatos evaluados, aunque Boosting gane en ROC-AUC/PR-AUC — distinción explícita entre “score de ranking” y “probabilidad interpretable”.




Figura 19: Curvas de calibración

10. Selección del umbral o política de priorización

10.1. Criterio operacional

Se comparan dos criterios sobre las predicciones de validación cruzada del modelo final (sin tocar test): índice de Youden (maximiza Sensibilidad + Especificidad – 1, depende solo del ranking) y umbral basado en costos ($c^* = CF_P / (CF_P + CF_N)$, requiere probabilidades bien calibradas).

10.2. Punto de operación seleccionado

El umbral basado en costos (0.1667) resulta en un costo total mayor (27.493) que el umbral de Youden (0.4874, costo 10.947), pese a ser teóricamente óptimo — porque asume probabilidades bien calibradas, y ya se mostró que no lo están. **Se selecciona el umbral de Youden** ($m^* = 0.4874$) como punto de operación del sistema final.

10.3. Sensibilidad a costos y capacidad

En los cinco escenarios probados (razón CF_N/CF_P entre 2 y 10), el costo de Youden se mantiene menor que el del umbral de costos — confirmando que la ventaja de Youden no depende de un supuesto de costos específico, sino de su robustez frente a la falta de calibración.




Figura 20: Sensibilidad del umbral a la razón de costos

11. Sistema seleccionado y test final

11.1. Configuración congelada

Modelo Gradient Boosting Machine (`gbm_fit`), hiperparámetros óptimos y umbral congelado en $m^* = 0.4874$ (Youden, elegido sin haber mirado test).




Figura 21: ROC de validación cruzada (Gradient Boosting)




Figura 22: ROC - Gradient Boosting

11.2. Evaluación única en test

Se abrió el conjunto de *test* ($N = 8,234$) por **una sola vez**:

Tabla 2: Evaluación del sistema final congelado en conjunto de test.

Indicador	Validación (CV)	Test final
Umbral o capacidad	$m^* = 0.4874$	$m^* = 0.4874$
Precision	0.3486	0.3462
Recall	0.8440	0.6214
Especificidad	0.6576	0.8511
F1	0.4557	0.4446
PR-AUC	0.4527	0.4380
Log-loss	0.5135	0.5190
Costo total o esperado	10916	2843
Número de acciones	7002	1664 llamadas

El sistema final sacrifica ≈ 6 puntos de Accuracy respecto al baseline, pero pasa de detectar 0% de los clientes potenciales a detectar 62.1% — el objetivo de negocio definido en la Sección 1.

12. Interpretación, errores y subgrupos

12.1. Patrones predictivos

Las variables con mayor peso relativo en el ensamble GBM fueron `nr.employed` (100 %), `euribor3m` (36.85 %), `cons.conf.idx` (23.41 %) y `age` (11.27 %). Estas relaciones representan patrones predictivos y no vínculos de causalidad directa.

12.2. Análisis de falsos positivos y falsos negativos

Los Falsos Negativos ($FN = 351$) corresponden a clientes compradores sin historial previo de campañas (`previous = 0.0997`). Los Falsos Positivos ($FP = 1,088$) promedian 40.5 años de edad y fueron contactados en períodos de alto empleo pero sin respuesta previa.

12.3. Auditoría por subgrupos

En subgrupos de campañas ejecutadas en meses de alta conversión (octubre/marzo), la prevalencia sube al 40% y la Sensibilidad del modelo se incrementa al 78.2 %.

13. Limitaciones, equidad y monitoreo

13.1. Limitaciones y transportabilidad

El 65 % del peso del modelo depende de indicadores macroeconómicos (`nr.employed`, `euribor3m`). Giros en la política monetaria pueden causar degradación del patrón (*Concept Drift*).

Además, a continuación se expondrán limitaciones técnicas del archivo `bank-additional-full.csv`.

- **Base de datos:** Un análisis exhaustivo de la base de datos `bank-additional-full.csv` revela que, si bien el motor de R no detecta celdas vacías bajo la notación tradicional de valores perdidos (NA), existe una presencia masiva de registros categóricos etiquetados como `unknown` (desconocido). Esto ocurre particularmente en variables socioeconómicas y de comportamiento crediticio histórico, tales como `education`, `default`, `housing`, `loan`, `job` y `marital`.
- **Sesgo de codificación (Encoding Bias):** Al transformar estas variables categóricas en matrices de diseño numéricas (dummy variables) para modelos paramétricos como Regresión Logística o de margen (SVM), la categoría `unknown` suele forzarse como un nivel artificial o interpretarse de manera errónea, alterando la ortogonalidad de la matriz de covariables y perdiendo la verdadera dimensión de la incertidumbre.

- **Violación de supuestos de aleatoriedad (MCAR / MAR):** Asumir que un cliente con nivel educativo unknown comparte la misma propensión de respuesta que el promedio observado introduce un sesgo de estimación. En la práctica comercial del sector bancario, un valor desconocido suele estar correlacionado con la reticencia del cliente a entregar información personal (efecto de privacidad), lo cual constituye por sí mismo un predictor latente de comportamiento.
- **Modelo seleccionado:** El modelo seleccionado y validado mediante Gradient Boosting Machine (GBM) maximiza la capacidad discriminativa del sistema; sin embargo, su implementación en un entorno de producción real presenta limitaciones analíticas y de calibración que deben ser explícitamente gobernadas. La utilización de técnicas de balanceo interno en los pliegues de entrenamiento (*down-sampling*) modifica de forma artificial la prevalencia real de la clase positiva (la cual es minoritaria en la población general del banco).
 - **Consecuencia técnica:** Al forzar una proporción equilibrada de clases durante el entrenamiento de los árboles de decisión, las probabilidades estimadas por el modelo sufren una distorsión sistemática. En la práctica, **el modelo sobrestima significativamente las probabilidades de aceptación** en comparación con la tasa de conversión real que experimenta la cartera de clientes.
 - **Impacto operacional:** Si se utilizara un umbral de decisión teórico estándar ($m = 0.5$), esta sobreestimación de probabilidades generaría un exceso de falsos positivos, disparando los contactos comerciales a clientes que en realidad tienen una propensión baja y encareciendo los costos operativos del call center.
 - **Mitigación aplicada:** Para contrarrestar este sesgo de sobreestimación, el sistema no confía en umbrales de probabilidad nominales, sino que adopta el punto operacional óptimo derivado del *Índice de Youden en validación* ($m^* = 0.4874$), el cual compensa matemáticamente el desplazamiento probabilístico inducido por el muestreo y ajusta el volumen de llamadas al umbral de eficiencia comercial requerido.
- **Desplazamiento Temporal (Data Drift y Concept Drift):** El análisis exploratorio de las variables temporales evidencia una naturaleza no estacionaria en las campañas de telemarketing del banco. Las condiciones macroeconómicas externas (tasas de interés como el *euribor*, inflación y estacionalidad mensual) alteran la distribución de los datos de entrada y la propensión de respuesta de los clientes.
 - **Consecuencia:** Un modelo estático entrenado con datos históricos sufrirá una degradación paulatina de su rendimiento (*Model Decay*), sobreestimando o subestimando las probabilidades de conversión en meses futuros.
 - **Acción de mitigación:** Se establece como política de monitoreo post-despliegue el seguimiento continuo del índice Population Stability Index (PSI) en las variables predictoras clave y la supervisión del Log-loss mensual. Si el PSI supera el umbral de alerta (> 0.25), el sistema deberá activar una pausa automática para recalibrar los hiperparámetros o reentrenar el modelo con una ventana deslizante de datos recientes.

13.2. Riesgos de equidad y uso

El modelo no debe utilizarse para la exclusión permanente de clientes sin historial de contacto previo: la caracterización de errores (Sección 12.2) mostró que el sistema detecta peor a los Falsos Negativos precisamente por su bajo *previous*, lo que podría traducirse en que clientes genuinamente nuevos —sin campañas previas— queden sistemáticamente sub-priorizados aunque tuvieran alta probabilidad real de aceptar. El sistema debe usarse como apoyo a la priorización de contacto, no como filtro de exclusión definitivo.

13.3. Sesgos demográficos y el problema de los datos enmascarados (*Unknown*)

El análisis exploratorio de la base de datos evidencia una alta concentración de registros etiquetados como “*unknown*” en variables sociodemográficas y de crédito (como *education*, *default* y *housing*).

- **Riesgo de equidad:** Tratar estas etiquetas como una categoría estándar sin distinción puede generar sesgos de estimación. En el sector bancario, la omisión de información suele reflejar restricciones de privacidad o perfiles de menor bancarización.
- **Impacto operacional:** Si el modelo penaliza o margina sistemáticamente a los clientes con datos faltantes debido a un sesgo algorítmico, se incurrirá en discriminación indirecta, excluyendo segmentos de mercado potencialmente rentables para la institución.

13.4. Desempeño y disparidad en subgrupos temporales

: La evaluación del modelo ganador (GBM) a lo largo de los distintos meses de la campaña revela una marcada inestabilidad en la tasa de conversión ($y = \text{“yes”}$), la cual oscila desde meses altamente equilibrados hasta periodos donde la clase mayoritaria supera el 90 %.

- **Consecuencia:** Los subgrupos temporales con menor densidad de casos positivos reducen la estabilidad de la sensibilidad del modelo, incrementando la tasa de falsos negativos en temporadas de baja actividad comercial si no se ajusta la capacidad de contacto.

14. Plan de Monitoreo y Gobernanza Post-Despliegue

Debido a que el modelo no debe utilizarse para la exclusión permanente de clientes sin historial crediticio:

- **Frecuencia:** revisión mensual de métricas operacionales (Sensibilidad, Precisión, volumen de llamadas, costo total).

- **Alertas:** desviación de la tasa de contacto positivo fuera de un rango esperado, o variación relevante del índice de estabilidad poblacional (PSI) de las variables macroeconómicas dominantes (`nr.employed`, `euribor3m`) respecto a los valores del período de entrenamiento.
- **Reentrenamiento:** si la Precisión observada cae de forma sostenida por debajo de un umbral mínimo operacional durante dos meses consecutivos, se debe pausar la asignación automatizada y recalibrar/reentrenar el modelo antes de reanudar su uso.
- **Reproducibilidad entre entornos:** se observaron pequeñas diferencias en resultados de SVM RBF (predicciones con NA en un fold específico) entre integrantes del equipo usando distintas versiones de R (4.5.3 vs. 4.6.1), atribuibles al algoritmo interno de muestreo aleatorio. El código maneja este caso explícitamente (ver Sección 8) y no afecta la validez de las conclusiones.

14.1. Indicadores de Alerta Temprana

- **Monitoreo del *Population Stability Index* (PSI):** Se establece la obligación de calcular mensualmente el PSI sobre los predictores críticos del modelo (tales como *euribor3m*, *age* y *previous*). Si el indicador supera el umbral crítico de alerta industrial ($PSI > 0.25$), se interpretará la existencia de un cambio severo en la distribución de entrada (*Data Drift*).
- **Control de Calidad Probabilística (*Log-loss* y Calibración):** Puesto que el submuestreo interno (*down-sampling*) induce una sobreestimación sistemática de las probabilidades de aceptación, se supervisará la entropía cruzada mensual. Un incremento sostenido del *Log-loss* evidenciará la presencia de *Concept Drift* (cambio en la relación entre el cliente y su propensión de compra).

14.2. Protocolo de Intervención

Ante una alerta de deriva de datos o degradación probabilística, el sistema automatizado del call center suspenderá la priorización algorítmica y activará una rutina de reentrenamiento utilizando una ventana deslizante de datos recientes (*sliding window*), asegurando que el modelo refleje la coyuntura macroeconómica actual.

15. Conclusiones

Se recomienda implementar el sistema de clasificación **Gradient Boosting Machine (GBM)** fijando el umbral operacional congelado en $m^* = 0.4874$ para la Gerencia de Marketing Directo. La política permite capturar el 62.14% de las ventas de depósitos a plazo ejecutando solo 1,664 llamadas por cada 8,234 clientes, reduciendo un 38.67% los costos de error frente al *baseline* no informativo.

15.1. Sistema Seleccionado y Política Comercial

El sistema predictivo seleccionado integra el clasificador **Gradient Boosting Machine (GBM)** con el umbral operacional óptimo derivado del **Índice de Youden en validación ($m^* = 0.4874$)**. Este diseño compensa matemáticamente la distorsión probabilística provocada por el balanceo artificial (**down-sampling**). Al ser evaluado bajo una política de priorización del **Top-20%** sobre el conjunto de test independiente ($N = 8,234$), el sistema logra una **reducción del 38.67%** en los costos operacionales totales frente a un modelo baseline no informativo.

15.2. Condiciones de Uso y Límites de Aplicación

- **Usuario y Decisión:** El sistema está destinado exclusivamente a la Gerencia de Marketing Directo para la asignación eficiente de listas de llamadas prioritarias a los ejecutivos del **call center**.
- **Restricciones críticas:** El modelo no debe utilizarse fuera del horizonte temporal de campañas de telemarketing estandarizadas ni emplearse para inferir causalidad en las decisiones de los clientes (cautela causal).
- **Evidencia pendiente:** Antes de una integración comercial masiva y sin supervisión humana, la institución debe implementar un módulo de calibración de probabilidades (**Platt Scaling** o **Isotonic Regression**) para corregir de manera nativa la sobreestimación inducida por el remuestreo y validar el comportamiento del sistema ante choques macroeconómicos externos.

Referencias

- [1] Moro, S., Cortez, P., & Rita, P. (2014). *A data-driven approach to predict the success of bank telemarketing*. Decision Support Systems, 62, 22-31.

A. Información de reproducibilidad

- **Entorno:** R versión 4.3.2 corriendo en x86_64-w64-mingw32.
- **Paquetes:** tidyverse (2.0.0), caret (6.0-94), gbm (2.1.8.1), pROC (1.18.5).
- **Semillas:** `set.seed(123)` para partición y resampling; `set.seed(143)` para tuning.

B. Resultados complementarios

Grillas de sintonización y curvas ROC de validación contenidas en el script reproducible `informe.Rmd`.

C. Declaración de uso de inteligencia artificial

El equipo utilizó Claude (Anthropic) como asistente durante el desarrollo del proyecto: en la estructuración del pipeline, la redacción y depuración de código para los ocho modelos, la explicación de conceptos estadísticos (sesgo-varianza, calibración, índice de Youden), y la identificación y corrección de errores metodológicos (down-sampling y preprocesamiento aplicados fuera de los folds de validación cruzada en versiones iniciales del código). El equipo dirigió las decisiones metodológicas (elección del modelo final, criterio de umbral, alcance de las correcciones aplicadas, partición del dataset), verificó cada resultado obtenido, contrastó de forma cruzada el trabajo de los distintos integrantes, y puede explicar y defender cada paso del pipeline, tanto en conjunto como individualmente.

Adicionalmente, el equipo sometió una versión avanzada del código y el informe a una revisión cruzada con una segunda herramienta de IA, independiente de la usada durante el desarrollo. Esa revisión detectó tres observaciones válidas —una inconsistencia menor en el cálculo del baseline de la tabla comparativa (mezclaba predicciones de test con las de validación cruzada de los demás modelos) y una aclaración faltante sobre el uso del umbral 0.5 como punto de comparación estandarizado, no como criterio de selección final— que fueron evaluadas, confirmadas y corregidas por el equipo antes de la entrega. Esta segunda revisión se usó exclusivamente como control de calidad adicional, no para generar contenido nuevo del informe.

D. Contribuciones del equipo

- **Alex Astudillo:** Formulación, datos y coordinación: problema, búsqueda, licencia, README y consolidación.
- **Martina Bedwell:** Preparación y modelos probabilísticos: baseline, logística, codificación, odds y calibración.
- **Sebastián Quintolén:** Evaluación y decisión: resampling, métricas, umbral, costos, subgrupos y recomendación.
- **Valentina Quiroz:** Modelos geométricos y locales: KNN, SVM lineal, kernels, escalamiento y tuning.
- **Izaak Ulloa:** Árboles y ensembles: árbol, Random Forest, boosting e importancia de variables.