

UNIVERSIDAD DE SANTIAGO DE CHILE
FACULTAD DE INGENIERÍA
Departamento de Ingeniería Industrial



PROYECTO INTEGRADOR: CLASIFICACIÓN SUPERVISADA

Perfilamiento de usuario para un determinado Banco

Integrantes del equipo

Alex Astudillo
Martina Bedwell
Sebastián Quintolen
Valentina Quiroz
Izaak Ulloa

PROFESOR:

Luis Rojo-González, Ph.D.

ASIGNATURA:

Estadística Aplicada

SANTIAGO – CHILE

2026

Resumen ejecutivo

Este informe aborda la optimización comercial de campañas telefónicas bancarias para la contratación de depósitos a plazo. La decisión la ejecuta la Gerencia de Marketing Directo para asignar listas prioritarias de contacto a ejecutivos de call center. La clase positiva corresponde a la aceptación del depósito (yes).

Se compararon 8 familias de clasificadores utilizando validación cruzada estratificada de 5 pliegues con submuestreo (*down-sampling*) aplicado dentro de cada pliegue. El modelo con mejor capacidad discriminativa fue Gradient Boosting Machine (GBM), alcanzando un ROC-AUC medio en validación de 0.8023. El punto operacional óptimo se determinó mediante el índice de Youden en validación ($m^* = 0.4874$), el cual demostró ser más robusto ante el desplazamiento probabilístico generado por el *down-sampling* que el umbral teórico de costos.

Al evaluar por única vez el sistema congelado sobre el conjunto de test ($N = 8,234$), se obtuvo una Sensibilidad (Recall) del 62.14 %, una Especificidad del 85.11 %, una Precisión del 34.62 % y un F1-Score de 0.4446. El sistema genera 1,664 llamadas comerciales, superando al *baseline* no informativo (Recall = 0%). Se recomienda implementar el modelo como priorizador dinámico, monitoreando mensualmente las variaciones en las tasas macroeconómicas clave (`nr.employed`, `euribor3m`).

Palabras clave: clasificación supervisada; telemarketing bancario; Gradient Boosting Machine; índice de Youden.

Índice

Resumen ejecutivo	I
Índice de tablas	V
Índice de figuras	VI
1. Problema y objetivos	1
1.1. Contexto y decisión	1
1.2. Unidad de observación, clases y horizonte	1
1.3. Costos de los errores y capacidad	1
1.4. Objetivos	1
2. Búsqueda y descripción del dataset	2
2.1. Proceso de búsqueda y alternativa descartada	2
2.2. Fuente, licencia y condiciones de uso	2
2.3. Población, período y variables	2
3. Calidad de datos, etiquetas y análisis exploratorio	3
3.1. Auditoría de calidad	3
3.2. Prevalencia y distribución de clases	3
3.3. Decisiones derivadas del EDA	3
4. Instante predictivo y construcción del target	4
4.1. Instante de corte y horizonte	4
4.2. Regla de construcción de las clases	5
4.3. Riesgos de fuga y errores de etiquetado	5
5. Partición y resampling	5
5.1. Diseño de la partición	5
5.2. Esquema de validación	5

5.3. Protección del conjunto de test	6
6. Preparación de datos y tratamiento del desbalance	6
6.1. Preprocesamiento	6
6.2. Estrategia de desbalance	6
6.3. Implementación sin leakage	6
7. Modelos evaluados y ajuste de hiperparámetros	6
7.1. Baseline y regresión logística	6
7.2. KNN	7
7.3. SVM lineal y con kernel	8
7.4. Árbol de clasificación	9
7.5. Random Forest y boosting	11
7.6. Diseño del tuning	12
8. Discriminación y métricas de validación	14
9. Calidad probabilística y calibración	15
9.1. Diagnóstico de calibración	15
9.2. Método de calibración, si corresponde	15
9.3. Efecto sobre las probabilidades y la decisión	15
10. Selección del umbral o política de priorización	15
10.1. Criterio operacional	15
10.2. Punto de operación seleccionado	15
10.3. Sensibilidad a costos y capacidad	15
11. Sistema seleccionado y test final	16
11.1. Configuración congelada	16
11.2. Evaluación única en test	17
12. Interpretación, errores y subgrupos	18

12.1. Patrones predictivos	18
12.2. Análisis de falsos positivos y falsos negativos	18
12.3. Auditoría por subgrupos	18
13. Limitaciones, equidad y monitoreo	18
13.1. Limitaciones y transportabilidad	18
13.2. Riesgos de equidad y uso	18
13.3. Plan de monitoreo	18
14. Conclusiones	19
Referencias	20
A. Información de reproducibilidad	20
B. Resultados complementarios	20
C. Declaración de uso de inteligencia artificial	20
D. Contribuciones del equipo	20

Índice de tablas

1.	Resultados de validación cruzada (5-fold CV) para los modelos evaluados	14
2.	Evaluación del sistema final congelado en conjunto de test.	17

Índice de figuras

1.	Distribución por edad	4
2.	Frecuencia de contactos por mes	4
3.	Distribución de la variable respuesta	5
4.	ROC - Regresión logística	7
5.	ROC de validación cruzada según k (KNN) (TRAIN)	7
6.	ROC de validación cruzada según k (KNN) (TEST)	7
7.	ROC de validación cruzada según C (SVM lineal)	8
8.	ROC - SVM lineal	8
9.	ROC de validación cruzada (SVM RBF)	9
10.	ROC - SVM RBF	9
11.	Diagrama del árbol de decisión	10
12.	Importancia de variables en el árbol	10
13.	ROC - Árbol de clasificación	11
14.	ROC de validación cruzada según mtry (Random Forest)	11
15.	Importancia de variables en Random Forest	12
16.	ROC - Random Forest	12
17.	Comparación [1]	13
18.	Comparación [2]	13
19.	Curvas de calibración	14
20.	Sensibilidad del umbral a la razón de costos	16
21.	ROC de validación cruzada (Gradient Boosting)	16
22.	ROC - Gradient Boosting	17

1. Problema y objetivos

1.1. Contexto y decisión

Las campañas de telemarketing telefónico masivo en la banca sufren de bajas tasas de conversión y un alto desperdicio de horas-hombre. El problema identificado consiste en la ineficiencia operacional del canal de ventas al realizar barridos comerciales no jerarquizados. La decisión operativa que apoya el sistema de clasificación es la jerarquización y generación de la cola de discado diario para los ejecutivos de call center, determinando a qué clientes contactar de manera prioritaria y a quiénes omitir en la campaña vigente.

1.2. Unidad de observación, clases y horizonte

- **Unidad de Observación:** Un contacto comercial telefónico a un cliente bancario individual.
- **Clase Negativa (no):** El cliente rechaza la propuesta de depósito a plazo.
- **Clase Positiva (yes):** El cliente acepta contratar el depósito a plazo.
- **Instante Predictivo (Corte):** Momento exacto previo a realizar la llamada comercial.
- **Horizonte de Evaluación:** Campaña trimestral de captación de fondos.
- **Población Objetivo:** Clientes de la base bancaria general elegibles para productos de inversión.

1.3. Costos de los errores y capacidad

- **Falso Positivo (FP):** Clasificar como aceptante a un cliente que rechazará la oferta. Costo operacional (CF_P): Pérdida directa del tiempo del ejecutivo y uso del canal telefónico, estimado en 1 unidad ($CF_P = 1$).
- **Falso Negativo (FN):** Clasificar como no aceptante a un cliente que habría contratado el depósito. Costo operacional (CF_N): Pérdida de oportunidad equivalente al margen financiero del depósito no captado, valorado en 5 unidades ($CF_N = 5$).
- **Restricción de Capacidad:** El call center dispone de capacidad operativa máxima para contactar hasta un 25 % de la cartera general por trimestre.

1.4. Objetivos

- **Objetivo General:** Desarrollar e implementar un sistema predictivo supervisado y una política de decisión operacional que optimice la conversión de depósitos a plazo y reduzca los costos de error comercial.

- **Objetivo Específico 1:** Entrenar 8 familias de clasificadores utilizando validación cruzada de 5 pliegues con preprocesamiento interno (*down-sampling*) para garantizar un ROC-AUC > 0.78 sin fuga de información (*data leakage*).
- **Objetivo Específico 2:** Determinar en validación un punto de corte (m^*) mediante el índice de Youden que logre capturar al menos el 60 % de los clientes compradores.
- **Objetivo Específico 3:** Evaluar una sola vez el sistema congelado en el conjunto de *test* (20 % fuera de muestra) para validar la reducción del costo esperado frente al *baseline*.

2. Búsqueda y descripción del dataset

2.1. Proceso de búsqueda y alternativa descartada

Se evaluaron datasets de dominios cercanos a Ingeniería Industrial (mantenimiento predictivo, fraude, entre otros). La decisión de usar Bank Marketing se basó en: (1) licencia clara y sin ambigüedad, (2) datos reales de una operación de negocio, y (3) la disponibilidad de más de 8 predictores al instante de decisión.

Alternativa descartada: Se descartó un “mirror” de Kaggle (prakharrathi25/banking-dataset-marketing-targets) porque su licencia estaba etiquetada inconsistentemente (CC0), contradiciendo la licencia CC BY 4.0 original que exige atribución explícita, además de carecer de versionado estable.

2.2. Fuente, licencia y condiciones de uso

- **Fuente y URL:** UCI Machine Learning Repository (ID 222). <https://archive.ics.uci.edu/dataset/222/bank+marketing>
- **Autores:** S. Moro, P. Cortez, y P. Rita (2014).
- **Licencia:** Creative Commons Attribution 4.0 International (CC BY 4.0).
- **Copia de trabajo:** Para garantizar trazabilidad, se subió una copia del archivo `bank-additional-full.csv` al repositorio de GitHub del grupo. El archivo `DATASET_README.md` de ese repositorio documenta la fuente original.

2.3. Población, período y variables

- **Población y Período:** Muestra de clientes contactados entre mayo de 2008 y noviembre de 2010.
- **Volumen Muestral:** 41,188 observaciones iniciales (41,176 tras eliminar 12 duplicados exactos).
- **Prevalencia Global:** 11.27 % de casos positivos (yes) vs 88.73 % de negativos (no).

- **Variables:** 21 atributos originales divididos en demográficos, financieros, de campaña previa e indicadores macroeconómicos.

La carpeta debe incluir `DATASET_README.md`, escrito en Markdown y legible en GitHub, con el diccionario completo de variables. Se evalúa la calidad documental, no el uso de una plataforma de control de versiones.

3. Calidad de datos, etiquetas y análisis exploratorio

3.1. Auditoría de calidad

Se removieron 12 duplicados exactos en el conjunto fuente (`datos[!duplicated(datos), ]`). Las variables continuas con delimitador decimal europeo (`emp.var.rate`, `cons.price.idx`, `cons.conf.idx`, `euribor3m`, `nr.employed`) fueron reconvertidas a tipo numérico. La categoría "unknown" en variables financieras (`default`, `housing`, `loan`) se mantuvo como un nivel explícito para preservar patrones conductuales.

3.2. Prevalencia y distribución de clases

La distribución de la clase respuesta refleja un desbalance severo: 36,536 registros negativos (`no`) y 4,640 registros positivos (`yes`), determinando una prevalencia del 11.27%. El análisis exploratorio reveló que clientes contactados en períodos con baja tasa Euribor o con antecedentes de suscripción previa (`poutcome = "success"`) presentan tasas de conversión superiores al 60%.

3.3. Decisiones derivadas del EDA

Se detectó que la variable `duration` (duración de la llamada) constituye un caso crítico de *Data Leakage*, dado que solo se conoce al finalizar el contacto comercial. Se decidió eliminarla permanentemente del pipeline de predicción.




Figura 1: Distribución por edad




Figura 2: Frecuencia de contactos por mes

4. Instante predictivo y construcción del target

4.1. Instante de corte y horizonte

El instante predictivo ocurre justo antes de generar la orden de llamada comercial diaria. La decisión se fundamenta exclusivamente en la información acumulada en la base de datos hasta $t - 1$.




Figura 3: Distribución de la variable respuesta

4.2. Regla de construcción de las clases

El target `y` es un factor binario con niveles `c("no", "yes")`, donde `yes` define la contratación efectiva del depósito a plazo.

4.3. Riesgos de fuga y errores de etiquetado

Al remover la variable `duration` (`datos %>% select(-duration)`), los predictores quedan acotados a atributos demográficos, financieros, métricas de campañas previas e indicadores económicos dinámicos.

5. Partición y resampling

5.1. Diseño de la partición

Se aplicó una partición estratificada del 80% para entrenamiento ($N = 32,942$) y 20% para prueba ($N = 8,234$) mediante `createDataPartition` fijando la semilla `set.seed(123)`. Ambas particiones conservaron exactamente el 11.27% de prevalencia de la clase positiva.

5.2. Esquema de validación

Dentro del conjunto de entrenamiento se configuró una Validación Cruzada Estratificada de 5 pliegues (5-fold CV) mediante la función `trainControl`.

5.3. Protección del conjunto de test

El conjunto de *test* permaneció intocado, empaquetado y congelado durante las fases de limpieza, codificación dummy, estandarización y sintonía de hiperparámetros.

6. Preparación de datos y tratamiento del desbalance

6.1. Preprocesamiento

Las categóricas se transformaron mediante codificación One-Hot (*dummyVars*) produciendo 52 variables numéricas. La estandarización (*center/scale*) se ejecutó como un paso interno en cada pliegue.

6.2. Estrategia de desbalance

Se implementó submuestreo (*down-sampling*) sobre la clase mayoritaria en entrenamiento.

6.3. Implementación sin leakage

Se especificó `sampling = "down"` dentro de `trainControl`. Esta instrucción aplica el submuestreo exclusivamente dentro de los sub-folds de entrenamiento de cada pliegue, evaluando la validación cruzada con la prevalencia real intacta (11.27%).

7. Modelos evaluados y ajuste de hiperparámetros

7.1. Baseline y regresión logística

Asigna la clase mayoritaria ("no"). Se ajustó un modelo binomial `glm`.




Figura 4: ROC - Regresión logística

7.2. KNN

Sintonizado mediante la grilla $k \in \{3, 7, 11, \dots, 51\}$, seleccionando $k = 47$.




Figura 5: ROC de validación cruzada según k (KNN) (TRAIN)




Figura 6: ROC de validación cruzada según k (KNN) (TEST)

7.3. SVM lineal y con kernel

SVM Lineal sintonizado con $C \in \{0.01, 0.1, 1, 10\}$ (óptimo $C = 0.1$). SVM RBF sintonizado con $\sigma \in \{0.01, 0.05\}$ y $C \in \{0.5, 1.0\}$ (óptimo $\sigma = 0.01, C = 1.0$).




Figura 7: ROC de validación cruzada según C (SVM lineal)




Figura 8: ROC - SVM lineal




Figura 9: ROC de validación cruzada (SVM RBF)




Figura 10: ROC - SVM RBF

7.4. Árbol de clasificación

Podado mediante parámetro de complejidad $cp \in [0.001, 0.05]$, seleccionando $cp = 0.001$.




Figura 11: Diagrama del árbol de decisión




Figura 12: Importancia de variables en el árbol




Figura 13: ROC - Árbol de clasificación

7.5. Random Forest y boosting

Random Forest entrenado con 300 árboles ($mtry \in \{2, 4, 9\}$, óptimo $mtry = 4$). Gradient Boosting Machine (GBM) sintonizado con $n.trees = 200$, $interaction.depth = 3$, $shrinkage = 0.10$ y $n.minobsinnode = 10$.




Figura 14: ROC de validación cruzada según mtry (Random Forest)




Figura 15: Importancia de variables en Random Forest




Figura 16: ROC - Random Forest

7.6. Diseño del tuning

Todas las grillas de hiperparámetros fueron optimizadas para maximizar el área bajo la curva ROC (ROC-AUC) sobre los pliegues de validación cruzada.




Figura 17: Comparación [1]




Figura 18: Comparación [2]

Tabla 1: Resultados de validación cruzada (5-fold CV) para los modelos evaluados

Modelo	ROC-AUC	PR-AUC	Log-loss	Precision	Recall	Especificidad	F1	Costo	Volumen
Baseline	0.5000	N/A	N/A	NaN	0.0000	1.0000	0.0000	18565	0
Logística	0.7946	0.4412	0.5201	0.3423	0.8428	0.6441	0.4470	11200	6986
KNN	0.7835	0.4120	0.5610	0.3321	0.8337	0.6307	0.4320	11850	7100
SVM lineal	0.7794	0.4015	0.5420	0.3275	0.8606	0.6218	0.4285	11920	7310
SVM kernel	0.7850	0.4024	0.5259	0.3524	0.8242	0.6639	0.4410	11150	6780
Árbol	0.7758	0.3980	0.5310	0.3412	0.8512	0.6485	0.4402	11380	7020
Random Forest	0.7945	0.4323	0.4470	0.3672	0.8599	0.6401	0.4667	10774	6470
Boosting	0.8023	0.4527	0.5135	0.3486	0.8440	0.6576	0.4557	10916	7002

8. Discriminación y métricas de validación




Figura 19: Curvas de calibración

Gradient Boosting Machine (GBM) obtuvo la mayor capacidad de separación discriminativa con un ROC-AUC medio de 0.8023 y un PR-AUC de 0.4527.

9. Calidad probabilística y calibración

9.1. Diagnóstico de calibración

El submuestreo ajusta la muestra de entrenamiento a una proporción 50/50, desplazando la escala probabilística asignada. Por este motivo, las salidas deben entenderse como un **score de ordenamiento (ranking)**.

9.2. Método de calibración, si corresponde

Se evaluaron los deciles de probabilidad predicha. Random Forest obtuvo el menor Log-loss (0.4470), mientras que GBM registró 0.5135, conservando monotonía en el ranking.

9.3. Efecto sobre las probabilidades y la decisión

Dada la distorsión del *down-sampling*, la definición de la política requiere seleccionar un umbral operacional optimizado.

10. Selección del umbral o política de priorización

10.1. Criterio operacional

Se comparó el umbral teórico de costos ($m = 0.1667$) contra la maximización del Índice de Youden ($J = \text{Sensibilidad} + \text{Especificidad} - 1$). El umbral teórico clasificó al 90% de la base como positiva debido a las probabilidades desplazadas por el submuestreo, sobrecargando las llamadas inútiles (27,493 unidades de costo).

10.2. Punto de operación seleccionado

El Índice de Youden identificó el punto óptimo en $m^* = 0.4874$, reduciendo el costo total en validación a 10,916 **unidades** y capturando el 84.4% de las conversiones en CV.

10.3. Sensibilidad a costos y capacidad

La política con $m^* = 0.4874$ genera un volumen de llamadas que se ajusta a la capacidad operacional del call center.




Figura 20: Sensibilidad del umbral a la razón de costos

11. Sistema seleccionado y test final

11.1. Configuración congelada

Modelo Gradient Boosting Machine (`gbm_fit`), hiperparámetros óptimos y umbral congelado en $m^* = 0.4874$.




Figura 21: ROC de validación cruzada (Gradient Boosting)




Figura 22: ROC - Gradient Boosting

11.2. Evaluación única en test

Se abrió el conjunto de *test* ($N = 8,234$) por **una sola vez**:

Tabla 2: Evaluación del sistema final congelado en conjunto de test.

Indicador	Validación (CV)	Test final
Umbral o capacidad	$m^* = 0.4874$	$m^* = 0.4874$
Precision	0.3486	0.3462
Recall	0.8440	0.6214
Especificidad	0.6576	0.8511
F1	0.4557	0.4446
PR-AUC	0.4527	0.4380
Log-loss	0.5135	0.5190
Costo total o esperado	10916	2843
Número de acciones	7002	1664 llamadas

El sistema final redujo los costos de error en un 38.67% respecto al *baseline* (2,843 vs 4,635 unidades), capturando el 62.14% de las contrataciones reales concentrando la fuerza de ventas en solo el 20.21% de la cartera.

12. Interpretación, errores y subgrupos

12.1. Patrones predictivos

Las variables con mayor peso relativo en el ensamble GBM fueron `nr.employed` (100 %), `euribor3m` (36.85 %), `cons.conf.idx` (23.41 %) y `age` (11.27 %). Estas relaciones representan patrones predictivos y no vínculos de causalidad directa.

12.2. Análisis de falsos positivos y falsos negativos

Los Falsos Negativos ($FN = 351$) corresponden a clientes compradores sin historial previo de campañas (`previous` = 0.0997). Los Falsos Positivos ($FP = 1,088$) promedian 40.5 años de edad y fueron contactados en períodos de alto empleo pero sin respuesta previa.

12.3. Auditoría por subgrupos

En subgrupos de campañas ejecutadas en meses de alta conversión (octubre/marzo), la prevalencia sube al 40 % y la Sensibilidad del modelo se incrementa al 78.2 %.

13. Limitaciones, equidad y monitoreo

13.1. Limitaciones y transportabilidad

El 65 % del peso del modelo depende de indicadores macroeconómicos (`nr.employed`, `euribor3m`). Giros en la política monetaria pueden causar degradación del patrón (*Concept Drift*).

13.2. Riesgos de equidad y uso

El modelo no debe utilizarse para la exclusión permanente de clientes sin historial crediticio.

13.3. Plan de monitoreo

- **Frecuencia:** Revisión mensual de métricas operacionales.
- **Alertas:** Desviación de la tasa de discado fuera del rango 18 % – 22 % o variación del Índice de Estabilidad Poblacional (PSI) de `euribor3m` superior a 0.25.
- **Reentrenamiento:** Si la Precisión cae por debajo del 25 % durante dos meses consecutivos, se pausará la asignación automatizada para reentrenar el modelo.

14. Conclusiones

Se recomienda implementar el sistema de clasificación **Gradient Boosting Machine (GBM)** fijando el umbral operacional congelado en $m^* = 0.4874$ para la Gerencia de Marketing Directo. La política permite capturar el 62.14% de las ventas de depósitos a plazo ejecutando solo 1,664 llamadas por cada 8,234 clientes, reduciendo un 38.67% los costos de error frente al *baseline* no informativo.

Referencias

- [1] Moro, S., Cortez, P., & Rita, P. (2014). *A data-driven approach to predict the success of bank telemarketing*. Decision Support Systems, 62, 22-31.

A. Información de reproducibilidad

- **Entorno:** R versión 4.3.2 corriendo en x86_64-w64-mingw32.
- **Paquetes:** tidyverse (2.0.0), caret (6.0-94), gbm (2.1.8.1), pROC (1.18.5).
- **Semillas:** `set.seed(123)` para partición y resampling; `set.seed(143)` para tuning.

B. Resultados complementarios

Grillas de sintonización y curvas ROC de validación contenidas en el script reproducible `informe.Rmd`.

C. Declaración de uso de inteligencia artificial

Se utilizaron herramientas de IA exclusivamente para asistencia en la redacción, edición ortográfica y depuración de sintaxis LaTeX/RMarkdown. Todos los análisis estadísticos fueron auditados por el equipo.

D. Contribuciones del equipo

- **Alex Astudillo:** Formulación, datos y coordinación: problema, búsqueda, licencia, README y consolidación.
- **Martina Bedwell:** Preparación y modelos probabilísticos: baseline, logística, codificación, odds y calibración.
- **Sebastián Quintolén:** Evaluación y decisión: resampling, métricas, umbral, costos, subgrupos y recomendación.
- **Valentina Quiroz:** Modelos geométricos y locales: KNN, SVM lineal, kernels, escalamiento y tuning.
- **Izaak Ulloa:** Árboles y ensembles: árbol, Random Forest, boosting e importancia de variables.