



INGENIERÍA INDUSTRIAL


UNIVERSIDAD DE SANTIAGO DE CHILE

PROYECTO INTEGRADOR CLASIFICACIÓN SUPERVISADA

Priorización de contacto para depósitos a plazo: Bank Marketing

Alex Astudillo · Martina Bedwell · Sebastián Quintolén ·
Valentina Quiroz · Izaak Ulloa
Machine Learning para Ingeniería Industrial

Estadística Aplicada



1. El problema debe conducir a una decisión

Defina qué se predice, quién actúa y por qué los errores tienen consecuencias distintas.

Problema y usuario


- Banco retail: priorizar llamadas de marketing telefónico
- Usuario: equipo de marketing directo / call center
- Decisión: a qué clientes contactar con agentes limitados
- Unidad: un contacto telefónico a un cliente
- Población: cartera de clientes susceptibles de campaña
- Ejemplo real: cliente sin llamadas previas, contactado en marzo

Target y costos

- Clases $y=(no,yes)$; positiva = “yes” (suscribe)
- Corte: antes de llamar; horizonte: resultado de esa llamada
- FP = llamada sin resultado; FN = venta perdida
- Costo asumido: $CF_N = 5 \times CF_P$ (sensib. 2 a 10)
- Capacidad: agentes no cubren toda la cartera
- FP: 1 unidad de costo | FN: 5 unidades de costo (supuesto)

Matriz de costos del problema

Real \ Predicho	Predice “no”	Predice “yes”
Real: no acepta	Correcto	FP — costo 1: llamada sin resultado
Real: sí acepta	FN — costo 5: venta perdida	Correcto



2. El dataset debe ser pertinente y trazable

La elección de datos se justifica por la decisión, no solo por disponibilidad.



Fuente y cobertura

- UCI ML Repository (ID 222), DOI 10.24432/C5K306
- CC BY 4.0; acceso 16-jul-2026
- Banca retail portuguesa, may-2008 a nov-2010
- 41.188 obs. (41.176 tras 12 duplicados)
- Prevalencia: 11.27% “yes” / 88.73% “no”
- Sin valores NA; “unknown” como categoría explícita

Pertinencia

- Target y binario, sin ambigüedad
- 20 predictores disponibles antes de llamar
- duration excluida: se conoce tras la llamada
- Descartado mirror Kaggle: licencia CC0 inconsistente
- Sin ID de cliente: posible dependencia entre filas
- 21 columnas: demográficas, financieras, campaña, macro
- Diccionario completo en DATASET_README.md

Prevalencia de la clase objetivo



3. El EDA debe cambiar decisiones metodológicas

Muestre dos o tres hallazgos que modificaron preparación, partición, métricas o modelamiento.

Hallazgos esenciales

- Desbalance severo: 11.3% clase positiva
- Sin NA; 12 duplicados exactos eliminados
- Prevalencia varía de 3% a ~50% según el mes
- “unknown” tratado como categoría propia
- pdays=999 codifica “nunca contactado”
- Sin ID de cliente: riesgo de dependencia entre filas
- Correlación visible entre poutcome=success y aceptación


```
# Eliminación de duplicados y variable con leakage
datos <- datos[!duplicated(datos), ]
datos <- datos %>% select(-duration)

# duration solo se conoce DESPUÉS de la llamada:
# incluirla sería Data Leakage severo.
datos$y <- factor(datos$y, levels = c("no", "yes"))
```

Limpieza y exclusión de duration por Data Leakage

Decisiones derivadas

- duration excluida (Data Leakage severo)
- Partición aleatoria, justificada con experimento
- Down-sampling solo dentro de cada fold
- Métrica de tuning: ROC-AUC, no accuracy
- Subgrupo elegido: mes de contacto
- Categorías con < 5 casos agrupadas (evita coef. inestables)
- EDA completo con 25+ gráficos en informe.html



4. La evaluación debe representar el uso futuro

Todos los modelos se comparan con los mismos resamples y el test permanece sellado.

Partición

- Aleatoria estratificada 80/20
- Train 32.942 / Test 8.234, ambos 11.27%
- 5-fold CV común a los 8 modelos
- Comparada vs. temporal: AUC 0.775 vs 0.714
- Test abierto una sola vez, al final
- Folds rolling-origin descartados: 1er fold = 1 solo mes


```
set.seed(123)
indices_train <- createDataPartition(
  datos$y, p = 0.8, list = FALSE
)
train <- datos[indices_train, ]
test <- datos[-indices_train, ]

control <- trainControl(
  method = "cv", number = 5,
  classProbs = TRUE,
  summaryFunction = twoClassSummary,
  sampling = "down" # balanceo SÓLO dentro de fold
)
```

Partición 80/20 y control con sampling="down"

Pipeline sin fuga

- Dummies + escalamiento dentro de cada fold
- preProcess como argumento de train()
- Hiperparámetros elegidos solo con validación
- sampling="down" exclusivo en fold de train
- set.seed(123) en cada partición/ajuste
- dummyVars(fullRank=TRUE) evita colinealidad perfecta
- Categorías nuevas en test alineadas a train



5. Compare familias con capacidades distintas

Explique qué aporta cada modelo y qué hiperparámetros controlan su complejidad.

Modelos mínimos

- Baseline: predice “no” siempre (Sens=0%)
- Regresión logística (odds, interpretable)
- KNN, $k \in [3, 51]$ (ampliada tras borde inicial)
- SVM lineal y RBF (paralelizados)
- Árbol de clasificación ($cp=0.001$)
- KNN: distancia euclídea, sensible a escala

```
set.seed(123)
gbm_fit <- train(
  y ~ ., data = train,
  method = "gbm", metric = "ROC",
  trControl = control,
  tuneGrid = expand.grid(
    n.trees = c(100, 200),
    interaction.depth = c(1, 3),
    shrinkage = c(0.01, 0.1),
    n.minobsinnode = 10
  ),
  verbose = FALSE
)
```

Ejemplo: ajuste de Gradient Boosting con train()

Ensembles y tuning

- Random Forest ($mtry=4$, $ntree=300$)
- Gradient Boosting ($n.trees$, $depth$, $shrinkage$)
- Tuning por ROC-AUC en validación cruzada
- SVM RBF y Árbol: grilla acotada por tiempo
- Ningún modelo excluido; los 8 se compararon
- `varImp()` disponible para RF, GBM y árbol
- 8 familias, misma fórmula y $\sim .$, mismo control

6. La discriminación se compara con incertidumbre

La mejor cifra puntual no basta: contraste baseline, variabilidad y prevalencia.


Evidencia requerida

- Tabla de validación con los 8 modelos
- Boosting: mejor ROC-AUC (0.802) y PR-AUC (0.453)
- IC 95% (resamples) por modelo, 5 folds
- Baseline: Accuracy 88.7% pero Sens=0%
- Boosting-RF-Logística: diferencia menor a 1 pto ROC

ROC-AUC en validación cruzada (5-fold CV)


Lectura crítica

- Accuracy no se usa como criterio único
- PR-AUC evita sobreestimar con 11.3% positivos
- Buen ranking no implica probabilidad correcta
- IC de Boosting se traslapa con RF y Logística
- Resultados de test no se muestran aquí



Rango (mín.-máx.) en 5 folds — se traslapan entre sí:

Boosting 0.792-0.816 | Random Forest 0.780-0.808 | Logística 0.785-0.805 | KNN 0.775-0.793



7. Las probabilidades deben ser confiables

Si la política usa probabilidades, evalúe calibración además de ranking.


Diagnóstico

- Log-loss: RF 0.447 (mejor) vs Boosting 0.514
- Curva de calibración: 3 modelos bajo la diagonal
- Sobreconfianza sistemática por down-sampling
- Ranking (AUC) sigue siendo válido igual
- RF mejor calibrado; Boosting mejor ranking

Corrección y validación

- No se recalibró (Platt/isotónica, fuera de curso)
- Se usó umbral basado en ranking (Youden)
- Umbral de costos falla por probabilidad inflada
- Costo con umbral de costos: 27.493 (peor)
- Costo con Youden: 10.947 (mejor)

Log-loss en validación (menor es mejor)



8. El punto de operación traduce el modelo en acción

Seleccione umbral o top-k mediante costos, capacidad y validación; no por 0.5 por defecto.

Política seleccionada

- Comparado: Youden (0.4874) vs. costos (0.1667)
- Sensibilidad CF_N/CF_P 2-10: Youden gana siempre
- Test: 6.219 VN / 351 FN / 1.088 FP / 576 VP
- Precision 34.6% / Recall 62.1% / F1 0.445
- 1.664 llamadas de 8.234 clientes (20.2%)

Consecuencia operacional

- Costo validación: 10.947 (Youden) vs 27.493
- Youden depende del ranking, no de calibración
- Baseline: 0 llamadas, 0% de compradores detectados
- Robusto a la razón CF_N/CF_P asumida
- Umbral congelado antes de abrir test

Costo total en validación, por criterio de umbral



9. El test evalúa un sistema ya congelado

Reporte una sola evaluación final e identifique dónde y por qué se equivoca el sistema.


Sistema final

- Algoritmo: Gradient Boosting (grilla en Sec. 7.5)
- Sin recalibrador; ranking validado por AUC
- Umbral: Youden, $m^*=0.4874$ (elegido en validación)
- Test (única vez): Accuracy 82.5%, Sens. 62.1%
- vs. baseline: Accuracy 88.7%, Sensibilidad 0%

Interpretación y subgrupos


- nr.employed, euribor3m dominan (no causal)
- FN típico: sin contacto previo (previous≈0.10)
- FP típico: ~40.5 años, sin éxito previo
- Mayor Sensibilidad en meses de alta conversión
- Meses con bajo soporte: interpretar con cautela

Sistema final vs. baseline (test, evaluación única)



Denominadores por mes (completar con datos reales del equipo):

n y prevalencia por mes disponibles en resultados/auditoria_subgrupo_mes.csv (ej.: oct./mar. ~40% prevalencia, ver informe)



10. La recomendación debe incluir límites y monitoreo


Cierre con una decisión accionable y condiciones explícitas para usar, pausar o actualizar el sistema.

Recomendación

- Gradient Boosting + umbral Youden (0.4874)
- Equipo de marketing directo del banco
- Clientes con perfil similar a 2008-2010
- Priorizar 1.664 de 8.234 contactos (20.2%)
- No usar para excluir clientes sin historial
- Revalidar con partición temporal antes de producción
- Ampliar grillas de SVM RBF y Boosting si hay tiempo

Monitoreo

- Resultado es cota optimista (temporal: AUC 0.714)
- 65% del peso depende de variables macro
- Revisión mensual: Sensibilidad, Precisión, volumen
- Alerta ante drift de PSI en indicadores macro
- Reentrenar si Precisión cae 2 meses seguidos
- sessionInfo() documentado para reproducibilidad
- Diferencias R 4.5.3 vs 4.6.1 explicadas en Limitaciones



PREGUNTAS Y DEFENSA TÉCNICA



8 minutos | Todos los integrantes deben poder defender datos, código, métricas y decisiones

