



PROPUESTA DE DATASET Y JUSTIFICACIÓN DEL PROBLEMA

Proyecto Integrador — Clasificación Supervisada

Estadística Aplicada, Ingeniería Industrial, Universidad de Santiago de Chile

Equipo: Alex Astudillo, Martina Bedwell, Sebastián Quintolen, Valentina Quiroz, Izaak Ulloa

Profesor: Luis Rojo-González, Ph.D.

1. CONTEXTO Y OBJETIVO DE ESTE DOCUMENTO

Antes de avanzar con el desarrollo completo del proyecto (limpieza, partición, modelos), el equipo definió y validó el dataset a usar, ya que de esta decisión depende el resto del trabajo: qué variables están disponibles, qué tan desbalanceado está el problema, y qué tan defendible es cada paso del informe técnico.

Este documento presenta la propuesta de dataset ya validada, con la justificación completa de por qué se considera una opción sólida en términos de licencia, tamaño, trazabilidad y pertinencia para Ingeniería Industrial.

2. DATASET PROPUESTO

Bank Marketing Dataset (UCI Machine Learning Repository)

URL permanente: <https://archive.ics.uci.edu/dataset/222/bank+marketing>

DOI: 10.24432/C5K306

Es un dataset de datos reales (no sintéticos), asociado a campañas de marketing directo por teléfono de una institución bancaria portuguesa.

El objetivo original de la institución era ofrecer un producto de depósito a plazo, y la variable a predecir (y) indica si el cliente contactado terminó suscribiendo el producto o no. La versión completa contiene 41.188 registros con 20 variables de entrada, ordenados cronológicamente entre mayo de 2008 y noviembre de 2010, y proviene del trabajo publicado por Moro, Cortez y Rita (2014) en la revista Decision Support Systems.

En palabras simples: es una base de datos real de un banco que llamó por teléfono a más de 40.000 personas para ofrecerles un depósito a plazo, y anotó quién dijo que sí y quién dijo que no. El trabajo del equipo es entrenar modelos que aprendan a predecir, antes de llamar, qué tan probable es que una persona diga que sí — para que el banco no llame a ciegas.

3. JUSTIFICACIÓN DE LA ELECCIÓN

3.1. Licencia clara, sin restricciones que discutir

El dataset tiene licencia CC BY 4.0, la cual permite compartir y adaptar el dataset para cualquier propósito, siempre que se dé el crédito correspondiente a los autores originales (Moro, Cortez y Rita) y al UCI Machine Learning Repository. No introduce ninguna restricción de uso comercial ni condiciones especiales que deban explicarse.

3.2. Son datos reales, no una simulación

Este dataset proviene de una operación real de un banco, no de un simulador. Esto permite hablar de resultados y limitaciones sin tener que aclarar constantemente que "esto es una simulación y podría no reflejar el comportamiento real": el comportamiento observado en los datos es comportamiento real de clientes.

3.3. Tiene un caso de fuga de información real, y eso es una fortaleza para el informe

El dataset incluye una variable llamada duration (duración de la llamada telefónica), que la documentación oficial de UCI señala explícitamente como un caso de fuga de información: esta duración solo se conoce después de terminada la llamada, momento en el cual ya casi se sabe si el cliente aceptó o no. Por eso, un modelo predictivo realista debe excluir esta variable del conjunto de entrenamiento y explicar por qué. Esto da un ejemplo concreto y bien documentado para desarrollar la sección de instante predictivo y construcción del target, en vez de tener que buscar el problema por cuenta propia.

3.4. Cumple de sobra con los predictores exigidos, sin necesidad de ingeniería de variables

La guía exige al menos 8 predictores disponibles al momento de la decisión, sin fuga de información. Este dataset los tiene disponibles directamente: edad del cliente, tipo de trabajo, estado civil, nivel educativo, situación crediticia (mora, hipoteca, préstamo personal), tipo de contacto, resultado de la campaña anterior, y cinco indicadores socioeconómicos agregados (tasa de variación del empleo, índice de precios al consumidor, índice de confianza del consumidor, tasa Euribor a 3 meses, número de empleados).

3.5. El problema de negocio es claro y fácil de defender, y es un problema de Ingeniería Industrial

El problema es: el equipo de marketing de un banco debe decidir a qué clientes vale la pena llamar para ofrecerles un depósito a plazo, dado un presupuesto y tiempo de agentes limitado. Es, en el fondo, un problema de asignación eficiente de un recurso escaso bajo incertidumbre:

- Recurso escaso: el tiempo de los agentes del call center. No se puede llamar a los ~41.000 clientes con el mismo esfuerzo.
- Función de costos explícita: un falso positivo (se llama a un cliente que no estaba interesado) implica tiempo de agente y recursos operativos sin resultado. Un falso negativo (no se llama a un cliente que sí habría aceptado) implica una venta potencial pérdida.
- Punto de operación bajo capacidad fija: priorizar los mejores candidatos dado un recurso limitado es un problema clásico de investigación de operaciones.
- Monitoreo en el tiempo: pensar en cuándo reentrenar el sistema es análogo a un gráfico de control de procesos.

En palabras simples: es un problema de "dónde poner el esfuerzo del equipo de llamadas", muy cercano a lo que se estudia en Ingeniería Industrial sobre asignación eficiente de recursos operativos.

3.6. Permite una partición justificada con evidencia, no solo por convención

Los registros están ordenados cronológicamente, desde mayo de 2008 hasta noviembre de 2010, lo que permitió al equipo evaluar tanto una partición aleatoria estratificada como una partición temporal antes de decidir. Se comparó el desempeño de un modelo de control bajo ambos esquemas: AUC de 0.775 con partición aleatoria frente a AUC de 0.714 con partición temporal. Se optó por la partición aleatoria estratificada por razones de cronograma y estabilidad de los folds resultantes, documentando esta decisión como una limitación explícita del sistema final.

3.7. Permite auditoría de subgrupos sin forzar nada

El equipo evaluó el desempeño del modelo final por subgrupo mensual de contacto, cumpliendo con la exigencia de auditar al menos un subgrupo operacional relevante de forma natural, dado que el propio análisis exploratorio mostró variación real de prevalencia entre meses.

4. TRAZABILIDAD: REPOSITORIO DE GITHUB

Para que el enlace al dataset sea permanente y esté bajo control del equipo, se subió una copia propia del archivo bank-additional-full.csv a un repositorio de GitHub del grupo.

El archivo DATASET_README.md de ese repositorio documenta la fuente original (UCI Machine Learning Repository; Moro, Cortez y Rita, 2014), su licencia CC BY 4.0, y el diccionario completo de variables, dejando claro que la copia en el repositorio es solo para trazabilidad y reproducibilidad, no porque el dataset haya nacido ahí.

5. TRANSPARENCIA FRENTE AL PROFESOR

Para ser transparentes y anticipar preguntas, esto es lo que el equipo documenta abiertamente en el informe:

- Persiste desbalance de clases: solo un 11,27% de los clientes contactados suscribió el producto. Se utiliza balanceo de clases (down-sampling) exclusivamente dentro de cada partición de entrenamiento, nunca en el conjunto de prueba.
- La variable duration se excluye del modelamiento por fuga de información, y se explica como parte del análisis del instante predictivo, no simplemente se omite sin comentario.
- Es un dataset ampliamente citado en cursos y trabajos de analítica bancaria; no es completamente inédito, aunque tiene variables reales e interpretables que permiten un análisis propio y original.
- Los datos corresponden a un contexto específico (banca portuguesa, 2008-2010), por lo que su transportabilidad a otros países o períodos se discute explícitamente como limitación.



- Se detectó y cuantificó drift temporal en la prevalencia de la variable objetivo, y se evaluó su impacto metodológico mediante un experimento de partición comparada (ver punto 3.6).

6. OBJETIVOS DEL PROYECTO

Objetivo general: construir y seleccionar, mediante un protocolo riguroso de validación, un sistema de clasificación que apoye la decisión de a qué clientes contactar, superando a un baseline no informativo en la detección de clientes con probabilidad real de aceptar el producto.

Objetivos específicos:

1. Comparar ocho familias de modelos de clasificación bajo el mismo protocolo de validación cruzada de 5 folds, con balanceo de clases y estandarización aplicados exclusivamente dentro de cada fold.
2. Seleccionar un umbral de decisión operacional comparando el índice de Youden contra un umbral basado en costos ($CF_P=1$, $CF_N=5$), con análisis de sensibilidad a este supuesto entre razones de 2 a 10.
3. Auditar el desempeño del sistema seleccionado en al menos un subgrupo operacional relevante (mes de contacto), caracterizando sus falsos positivos y falsos negativos.

7. FICHA TÉCNICA DEL DATASET

Fuente: UCI Machine Learning Repository, "Bank Marketing" (ID 222)

URL permanente: <https://archive.ics.uci.edu/dataset/222/bank+marketing>

DOI: 10.24432/C5K306

Autores: S. Moro, P. Cortez, P. Rita

Licencia: Creative Commons Attribution 4.0 International (CC BY 4.0)

Fecha de acceso del equipo: 16 de julio de 2026

Citación: Moro, S., Cortez, P., & Rita, P. (2014). A Data-Driven Approach to Predict the Success of Bank Telemarketing. Decision Support Systems, 62, 22-31.

Población: clientes contactados telefónicamente por un banco retail portugués.

Período: mayo de 2008 a noviembre de 2010.

Tamaño: 41.188 observaciones iniciales; 41.176 tras eliminar 12 duplicados exactos.

Prevalencia: 11,27% de casos positivos ("yes") frente a 88,73% de casos negativos ("no").

Variable excluida por leakage: duration (duración de la llamada telefónica).

8. LINKS DE REFERENCIA



Página oficial del dataset (UCI Machine Learning Repository):
<https://archive.ics.uci.edu/dataset/222/bank+marketing>

Licencia CC BY 4.0 (texto oficial): <https://creativecommons.org/licenses/by/4.0/>

Publicación original (Moro, Cortez y Rita, 2014): referencia citada en la página de UCI.

Copia del equipo en GitHub (enlace permanente):
https://github.com/izaakulloa/Equipo_10/tree/main